데이터분석 Mini Project · Day 1 EDA

신약 후보물질 독성 예측 EDA

탐색으로 세운 가설 10개, 검증 결과와 효과

3조 · 발표자 [이름]

김산, 김인성, 민영은, 박지원, 이승준, 이휘호

SK AX SKALA

한 장 요약

가설 10개를 검증해 얻은 결론은 세 줄이다

1

독성을 가르는 정보는 분자 구조에 있다

물성 4개만 쓰면 F1 0.70, 구조 지문을 쓰면 0.82 · 가설 4, 5, 6

2

기름지고 평평한 분자일수록 독성이 높다

clogp 구간별 독성 16% → 68%, 화학 파생변수로 F1 +0.06 · 가설 1, 3, 8

3

점수는 모델보다 검증 방식이 더 크게 바꾼다

처음 보는 계열의 분자에선 독성 재현율 0.76 → 0.58 · 가설 9, 10

01 문제 정의

ADMET의 마지막 관문, 독성(T)을 미리 거른다

후보물질 발굴 단계에 신약 개발 비용의 **37.9%**가 들어간다. 임상 전에 독성을 예측하면 시행착오를 줄일 수 있다.

과제: 화합물 구조와 물성으로 **독성 여부를 맞히는 이진 분류**, 평가지표는 F1

주의: 라벨이 직관과 반대

Positive(1)가 “독성 없음”이다. 가장 비싼 실수는 독성 물질을 안전하다고 판정하는 것(0을 1로 예측)이므로, F1과 함께 독성 클래스 재현율도 봐야 한다.

1

독성 없음 (Positive)

4,542개 · 54.4%

0

독성 있음 (Negative)

3,807개 · 45.6%

컬럼 3,078개는 사실 다섯 묶음이다

묶음	컬럼 수	의미
SMILES	1	분자 구조를 글자로 쓴 “주소”
ECFP	1,024	원자 연결 구조 지문 (0/1)
FCFP	1,024	원자 기능(수소결합 등) 지문 (0/1)
PTFP	1,024	대표 부분구조 패턴 지문 (0/1)
물성	4	MolWt, clogp, sa_score, qed
label	1	1 = 독성 없음, 0 = 독성 있음

발견 행이 분자량 순으로 정렬돼 있다(첫 행 94Da, 마지막 1,242Da) → 가설 9

8,349
화합물 (행)

0 / 0 / 0
결측 / 중복 / 라벨 모순

54 : 46
독성 없음 : 있음, 균형 잡힘

탐색 과정

앞 단계에서 본 것이 다음 가설의 근거가 됐다

1 데이터	2 물성	3 구조(지문)	4 유사도	5 화학 지식
라벨 방향, 행 순서	**라벨별 분포 비교**	**피처 묶음, 비트 비교**	**QSAR, 닮은 분자**	**SMILES 부분구조**
1이 “독성 없음”, 행이 분자량 순으로 정렬	clogp만 두 분포가 뚜렷이 어긋남	물성만으로는 AUC 0.66이 한계	분자 79%가 아주 닮은 이웃을 가짐	지용성 신호를 구조로 다시 확인
→ 가설 9	→ 가설 1, 2, 3	→ 가설 4, 5	→ 가설 6, 7, 10	→ 가설 8

예: 물성에서 지용성이 가장 강하자(2단계) 산성기·방향족 같은 구조로 같은 현상을 확인했고(5단계), 닮은 분자가 많다는 사실(4단계)에서 점수가 부풀었을 가능성을 의심했다(가설 10).

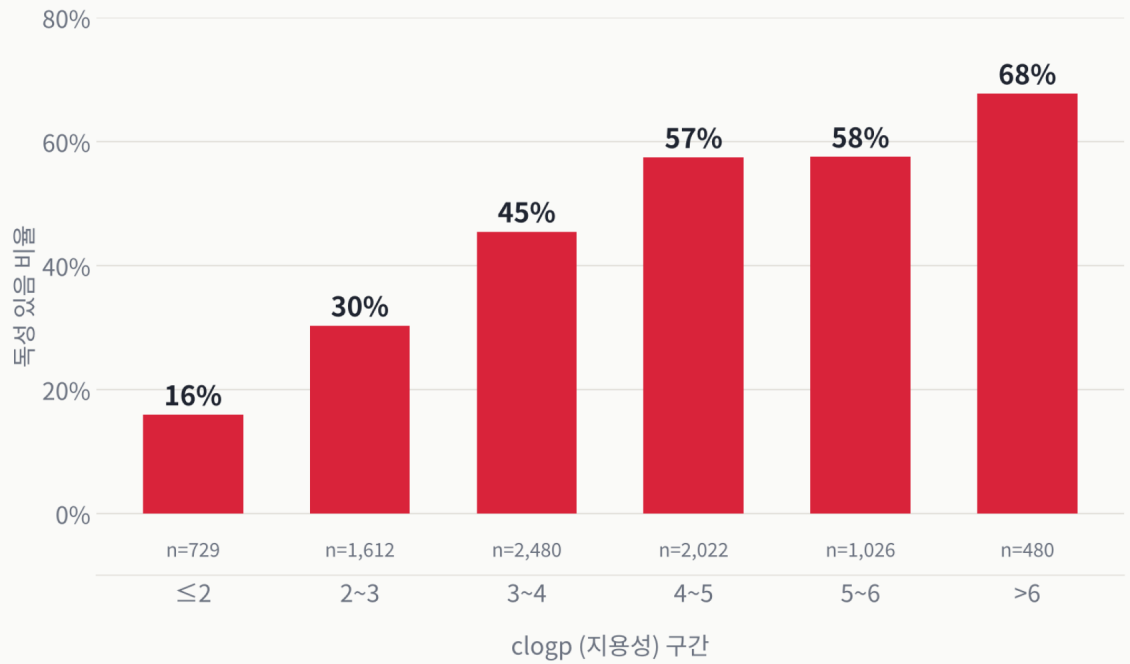
가설 한눈에

10개 중 9개 채택, 효과가 없던 1개는 기각

#	가설	효과	판정
1	지용성(clogp)이 높을수록 독성이 높다	독성 비율 16% → 68%	채택
2	분자량은 독성과 무관하다	AUC 0.50, p=0.40	채택
3	Lipinski 규칙을 어길수록 독성이 높다	위반 0 → 2개: 43% → 58%	채택
4	독성 정보는 물성보다 구조에 있다	F1 0.70 → 0.82	채택
5	특정 부분구조가 독성을 가른다	비트 하나로 최대 18%p 차이	채택
6	구조가 닮으면 독성도 닮는다 (QSAR)	라벨 일치 76% (무작위 50%)	채택
7	닮은 이웃의 라벨을 변수로 넣으면 좋아진다	F1 0.817 → 0.818	기각
8	산성기·산소는 안전, 방향족·니트로는 독성	물성 모델 F1 0.70 → 0.76	채택
9	행 정렬 때문에 점수가 낮게 나왔다	섞기 전후 F1 0.72 → 0.82	채택
10	닮은 분자 암기로 점수가 부풀었다	독성 재현율 0.76 → 0.58	채택

가설 1 · 2 물성

기름에 잘 녹는 분자일수록 독성이 많다



막대 = 그 구간에서 독성 있는 분자의 비율, n = 분자 수

관찰 물성 4개의 분포를 독성/안전으로 겹쳐 보니 clogp만 뚜렷이 갈렸다

가설 기름에 잘 녹으면 몸에 쌓여 독성이 높을 것. 분자량은 무관할 것

결과 **16% → 68%**

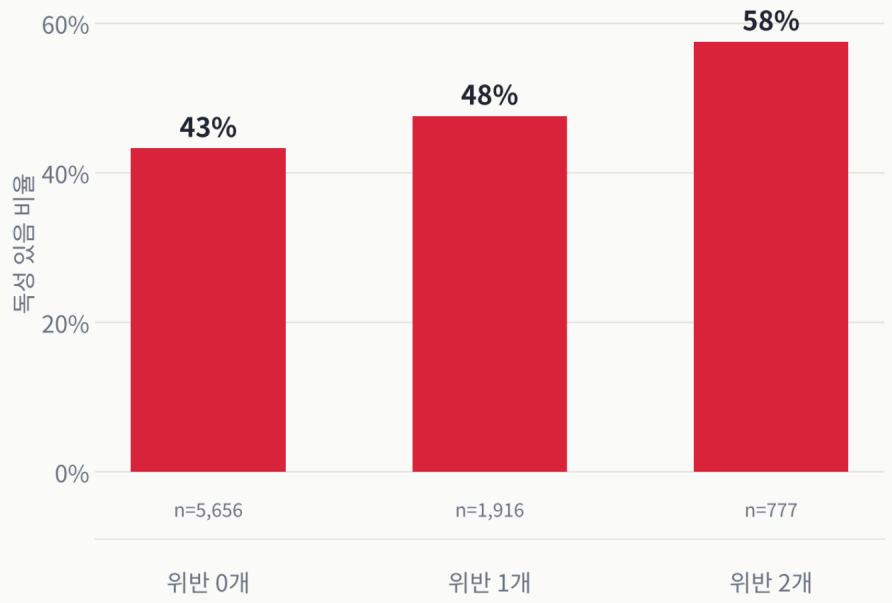
두 가설 모두 채택. 분자량은 독성/안전 중앙값이 441로 같다(p=0.40)

용어 풀이

clogp 물보다 기름에 얼마나 잘 녹는지(지용성). 높을수록 세포막을 잘 통과하고 지방에 쌓인다

가설 3 약물 규칙

“약다운” 규칙을 어길수록 독성이 늘어난다



위반 개수 = 분자량 500 초과, clogp 5 초과 중 해당하는 개수

Lipinski 규칙(Rule of 5)이란?

1997년 화이자 연구원 Lipinski가 정리한 “먹는 약이 되기 좋은 분자”의 조건. 분자량 500 이하, logP 5 이하, 수소결합 주개 5개 이하, 받개 10개 이하. 우리 데이터엔 앞의 두 값만 있어 그 둘로 셌다.

찾은 과정 분자량이 혼자선 무의미했다(가설 2) → 신약 개발에서 분자량을 어디에 쓰는지 찾아보니 지용성과 묶어 쓰는 이 규칙이 있었다

가설 규칙을 어길수록 독성이 높을 것

결과 **채택.** 위반 0개 43% → 2개 58% (+15%p)

물성 전처리 점검

이상치도, 겹치는 변수도 지우지 않기로 했다

이상치 (IQR)

IQR = 가운데 50%가 퍼진 폭. 그 1.5배 밖이면 이상치로 본다

분자량 이상치 **130개**의 독성 비율은

22% vs 전체 46%

무거운 분자는 오히려 안전한 쪽. 이상치가 신호라서 **지우면 정보를 버리는 셈**

다중공선성 (VIF)

VIF = 한 변수를 나머지로 얼마나 설명할 수 있나. 10을 넘으면 겹친다고 본다

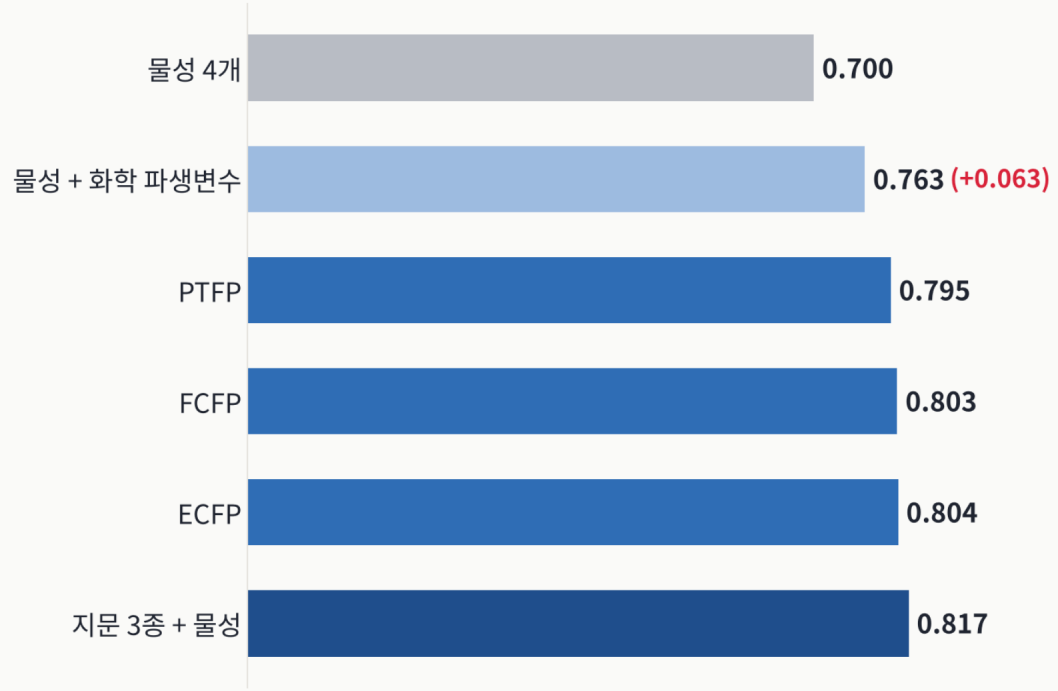
물성 4개의 VIF는 최대

2.85 (MolWt)

4개 모두 유지. 주의: 상수항 없이 계산하면 34까지 부풀어 잘못 지울 수 있다

가설 4 구조 vs 물성

구조 정보를 쓰면 F1이 0.70에서 0.82로 오른다



같은 RandomForest에 피처 묶음만 바꿔 넣은 F1 (섞은 5-fold 평균)

관찰 가장 강한 물성 clogp도 혼자서는 AUC 0.66이 한계

가설 독성을 가르는 정보는 분자 구조에 더 많을 것

결과 **채택.** 물성만 0.70, 지문 하나 0.80, 지문 3종 + 물성 0.82

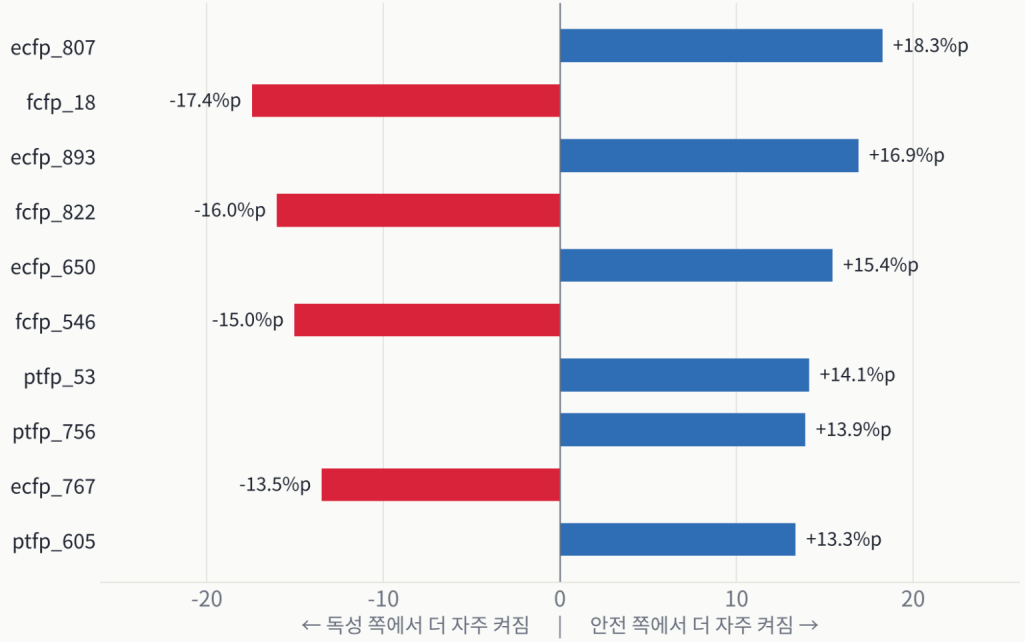
용어 풀이

지문(fingerprint) 분자에 특정 부분구조가 있으면 1, 없으면 0으로 적은 1,024칸 체크리스트. ECFP는 원자 연결, FCFP는 원자 역할, PTFP는 대표 부분구조 기준

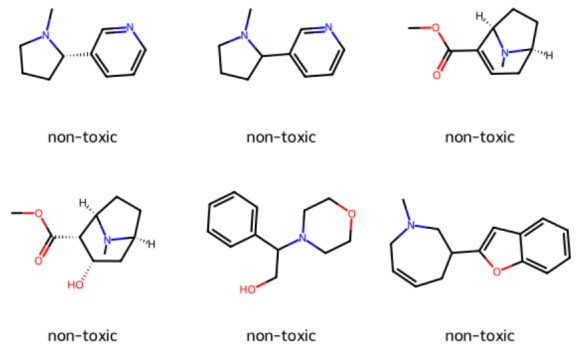
F1 과제 평가지표. 1에 가까울수록 잘 맞힘

가설 5 핵심 부분구조

독성 쪽 대표 비트는 ‘염기성 질소’로 보인다



막대 = 안전 분자에서 켜진 비율 − 독성 분자에서 켜진 비율. 빨강 = 독성 쪽

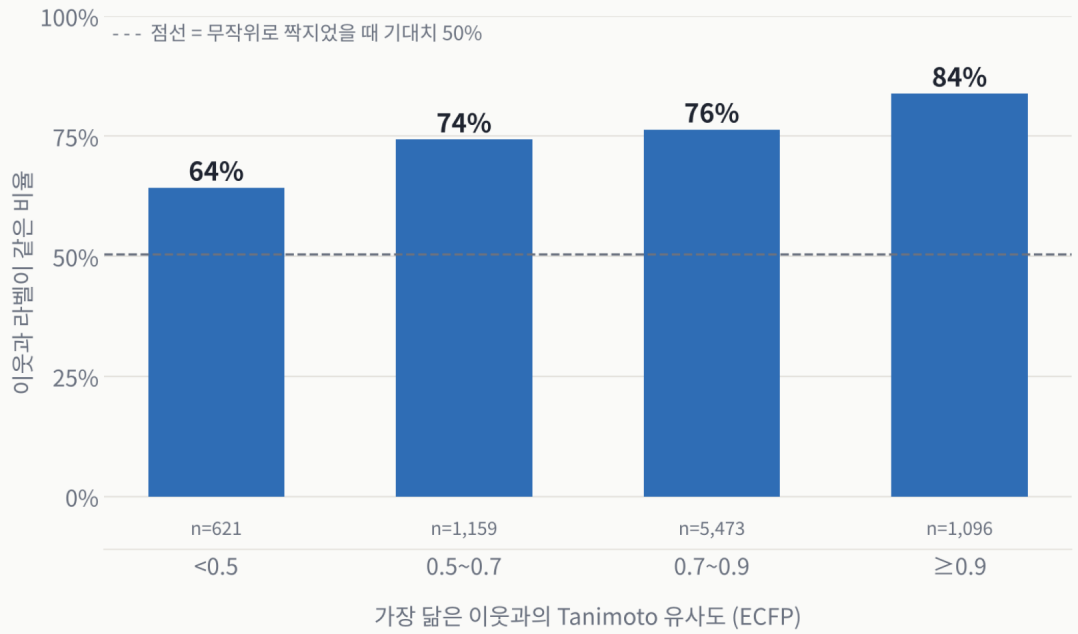


결과 fcfp_18이 켜진 분자들은 공통으로 **3차 아민 질소**를 가진다. 켜지면 독성 55%(꺼지면 37%), 지용성까지 높으면 **72%**

시행착오 “독성에 자주 나오는 비트 수”는 AUC 0.50. 흔한 비트는 양쪽에 다 많아, **빈도 말고 차이**로 골라야 했다

가설 6 · 7 QSAR

닮은 분자는 독성도 닮는다, 예외는 20%



분자마다 가장 닮은 분자를 찾아, 두 분자의 라벨이 같은 비율을 유사도 구간별로 표시

QSAR이란?

"구조가 비슷한 물질은 성질도 비슷하다"는 가정으로 구조에서 독성을 예측하는 방법. 닮은 정도는 두 분자의 지문이 겹치는 비율(Tanimoto, 0~1)로 잰다

관찰 분자의 79%가 유사도 0.7 이상인 이웃을 가진다

가설 6 **채택.** 이웃과 라벨 일치 76%(무작위 50%). 단 아주 닮은 쌍의 20%는 라벨이 반대(activity cliff)

가설 7 **기각.** 이웃 라벨을 변수로 넣어도 F1 0.817 → 0.818. 정보가 이미 지문에 있다

가설 8 화학 지식 파생변수

산성기·산소는 안전 쪽, 방향족·니트로는 독성 쪽

관찰 지용성이 가장 강했고, 지문 비트는 설명이 어렵다

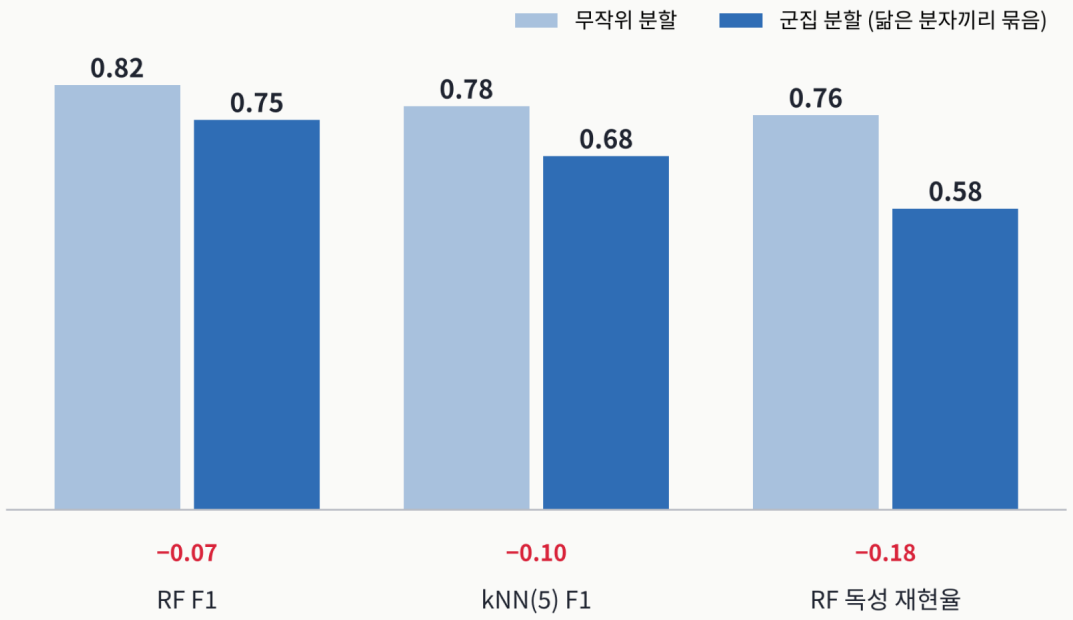
가설 같은 현상을 화학자가 아는 구조로도 볼 수 있을 것

구조 (SMILES에서 추출)	쉽게 말하면	결과 (전체 독성 46%)	판정
카복실산기	몸에서 이온이 돼 세포막을 잘 못 지나감	독성 29% (806개)	채택
산소 원자 수	물과 친한(극성) 성질 → 지용성 낮춤	많을수록 안전 (AUC 0.63)	채택
방향족 비율	평평한 고리, DNA·단백질 틈에 끼어듦	많을수록 독성 (AUC 0.44)	채택
니트로기	교과서에 나오는 대표 독성 구조	독성 71% (35개)	채택*
염소 / 브롬	할로겐 원소	Cl 50% / Br 표본 부족	Cl만

F1 +0.06 물성 4개 모델에 더하면 F1 0.70 → 0.76, 독성 재현율 0.63 → 0.70. 지문 모델엔 효과 없음(정보 중복). 대신 “왜 독성인가”를 말로 설명할 수 있게 됐다. *표본 적음

가설 9 · 10 검증 방식

처음 보는 계열에선 독성 물질의 42%를 놓친다



같은 모델을 두 방식으로 나눠 시험. 아래 빨간 숫자 = 떨어진 폭

가설 9 행이 분자량 순으로 정렬돼, 섞지 않고 나누면 점수가 낮게 나온다 → **채택**, F1 0.72 → 0.82

가설 10 닮은 분자가 많아 점수의 일부는 “암기” → **채택**, 독성 재현율 0.76 → 0.58

비유로 보면

무작위 분할 = 연습문제와 거의 같은 문제가 시험에 나옴
군집 분할 = 닮은 분자끼리 묶어 한쪽에만 둠. 처음 보는 유형으로 치는 시험

결론과 Day 2 계획

구조가 주연, 지용성이 조연, 평가 설계가 먼저

발견

구조가 핵심. 지문이 물성보다 정보가 많고, 닮은 분자는 독성도 닮는다(일치 76%)

지용성 이야기가 일관. clogp 16% → 68%, 화학 파생변수로 물성 모델 F1 +0.06

점수는 검증 방식이 정한다. 같은 RF가 0.72 / 0.82 / 0.75, 처음 보는 계열에선 독성 재현율 0.58

Day 2에 할 일

1. 섞은 5-fold와 군집 분할 점수를 항상 함께 보고
2. RF·XGBoost·LightGBM vs Tanimoto kNN(k=3)
3. 독성 재현율을 올리는 임계값 조정
4. 거의 상수인 컬럼 제거 전후 비교
5. predict_input의 train 유사도로 예측 신뢰도 표시

SK AX SKALA

부록

이 자료에 나오는 용어 여섯 개

지문 (Fingerprint)

분자에 특정 부분구조가 있으면 1, 없으면 0으로 적은 1,024칸 체크리스트

clogp (지용성)

기름에 얼마나 잘 녹는지. 높을수록 세포막을 잘 통과하고 몸에 쌓이기 쉽다

AUC

변수 하나로 두 그룹을 가르는 힘. 0.5면 동전 던지기, 0.5에서 멀수록 강하다

p값

차이가 우연일 확률. 0.05보다 작으면 의미 있는 차이로 본다

Tanimoto 유사도

두 분자의 지문이 겹치는 정도. 0(전혀 다름) ~ 1(완전히 같음)

F1

과제 평가지표. 정밀도와 재현율의 조화평균, 1에 가까울수록 잘 맞힌다