3조 독성 예측 EDA 정리 (팀 공유용)

Oct 19, 2026 · @San Kim

탐색하며 본 것에서 가설 10개를 세웠고 9개를 채택했다. 결론은 세 줄이다.

	결론	근거 숫자
1	**독성 정보는 분자 구조에 있다**	물성만 F1 0.70 → 구조 지문 0.82
2	**기름지고 평평한 분자일수록 독성이 높다**	clogp 구간별 독성 16% → 68%, 화학 파생변수 F1 +0.06
3	**점수는 검증 방식이 크게 바꾼다**	처음 보는 계열에서 독성 재현율 0.76 → 0.58

가설마다 **관찰**(무엇을 보고) → **가설** → **검증**(어떻게) → **결과와 효과**(얼마나) → **그림이 의도에 맞나** 순서로 적었다. 모델 점수는 모두 같은 RandomForest(150그루)를 같은 섞은 5-fold로 잰 값이라 서로 비교할 수 있다.

탐색 과정

탐색은 다섯 단계로 진행했고, 앞 단계에서 본 것이 다음 가설의 근거가 됐다.

1. **데이터 이해.** 라벨이 1 = 독성 없음이고, 행이 분자량 순으로 정렬돼 있다는 걸 발견 → 가설 9
2. **물성.** 라벨별 분포를 겹쳐 보니 clogp만 두 분포가 뚜렷이 어긋남 → 가설 1, 2, 3
3. **구조(지문).** 물성 중 가장 강한 clogp도 AUC 0.66이 한계라 구조를 봄 → 가설 4, 5
4. **유사도(QSAR).** 분자 79%가 아주 닮은 이웃을 가짐 → 가설 6, 7, 10
5. **화학 지식.** 가설 1의 지용성 신호를 구조로도 확인하려고 SMILES에서 부분구조를 뽑음 → 가설 8

가설 번호는 발표 자료와 같다. 아래는 가설 번호 순서로 정리했다.

가설 10개 한눈에

#	가설	효과	판정
1	지용성(clogp)이 높을수록 독성이 높다	독성 비율 16% → 68%, 단일 AUC 0.66	채택
2	분자량은 독성과 무관하다	AUC 0.50, p=0.40	채택
3	Lipinski 규칙을 어길수록 독성이 높다	위반 0 → 2개: 43% → 58%	채택
4	독성 정보는 물성보다 구조에 있다	F1 0.70 → 0.82	채택
5	특정 부분구조가 독성을 가른다	비트 하나로 최대 18%p 차이	채택

#	가설	효과	판정
6	구조가 닮으면 독성도 닮는다 (QSAR)	라벨 일치 76% (무작위 50%)	채택
7	닮은 이웃의 라벨을 변수로 넣으면 좋아진다	F1 0.817 → 0.818	기각
8	산성기·산소는 안전, 방향족·니트로는 독성	물성 모델 F1 0.70 → 0.76	채택
9	행 정렬 때문에 점수가 낮게 나왔다	섞기 전후 F1 0.72 → 0.82	채택
10	닮은 분자 암기로 점수가 부풀었다	독성 재현율 0.76 → 0.58	채택

데이터 이해

데이터는 깨끗하고 균형 잡혀 있다. 다만 라벨 방향과 행 순서 두 가지는 반드시 기억해야 한다.

확인한 것	결과	의미
크기	8,349행 × 3,078열	행 하나 = 화합물 하나
컬럼 구성	SMILES 1, ECFP·FCFP·PTFP 각 1,024, 물성 4, label 1	3,078개가 사실 다섯 묶음
결측 / 중복 / 라벨 모순	0 / 0 / 0	정제 작업 거의 불필요
라벨 비율	독성 없음 54.4% : 독성 있음 45.6%	오버샘플링 불필요
라벨 방향	1 = 독성 없음(Positive), 0 = 독성 있음	F1만 보면 독성 물질을 놓치는 실수가 잘 안 보인다. 독성 재현율을 함께 본다
행 순서	첫 행 94Da, 마지막 행 1,242Da (행 번호와 분자량 상관 0.78)	섞지 않고 나누면 점수가 왜곡된다 → 가설 9

가설 1·2 · 지용성은 강하고, 분자량은 무관하다

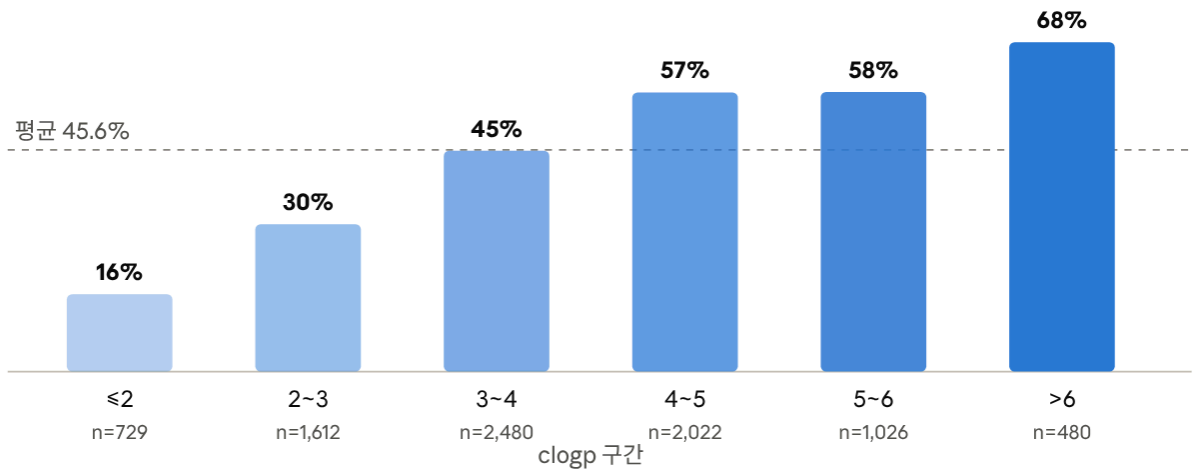
한 줄 결론: clogp가 높을수록 독성 비율이 16% → 68%로 오른다. 분자량은 관계없다.

단계	내용
관찰	물성 4개의 분포를 독성/안전으로 겹쳐 보니(KDE) clogp 만 뚜렷이 갈렸다
가설	(1) 기름에 잘 녹으면 몸에 쌓여 독성이 높다 (2) 분자량은 무관하다

단계	내용
검증	clogp 6구간별 독성 비율, 물성별 단일 AUC와 Mann-Whitney 검정
결과·효과	둘 다 채택. clogp 단일 AUC 0.66, 분자량은 0.50(p=0.40)
그림 점검	KDE는 "다르다"만 보여줘서 구간별 비율 막대로 바꿨다. 4~5와 5~6 구간은 57%로 같다

clogp가 높을수록 독성 비율이 16%에서 68%로 오른다

clogp(지용성) 구간별 독성 있는 분자 비율, 막대 아래는 분자 수



train.csv 8,349건 · clogp 6구간

물성	단일 AUC	p값	독성 중앙값	안전 중앙값
clogp	0.337	9e-145	4.15	3.37
qed	0.548	2e-14	0.538	0.571
sa_score	0.541	7e-11	3.03	3.14
MolWt	0.495	0.40	441.0	441.7

용어 · **clogp** 물보다 기름에 얼마나 잘 녹는지 · **AUC** 변수 하나로 두 그룹을 가르는 힘, 0.5면 동전 던지기이고 0.5에서 멀수록 강함

가설 3 · 약물 규칙을 어길수록 독성이 늘어난다

한 줄 결론: Lipinski 규칙 위반이 0개면 독성 43%, 2개면 58%(+15%p).

Lipinski 규칙(Rule of 5)이란? 1997년 화이자 연구원 Lipinski가 정리한 "먹는 약이 되기 좋은 분자"의 조건이다. 분자량 500 이하, logP 5 이하, 수소결합 주개 5개 이하, 받개 10개 이하. 우리 데이터엔 앞의 두 값만 있어 그 둘로 셈다.

단계	내용
관찰	분자량은 혼자서는 신호가 없었다(가설 2)
찾은 과정	신약 개발에서 분자량을 어디에 쓰는지 찾아보니, 지용성과 묶어 "약다운가"를 판단하는 이 규칙이 있었다
가설	규칙을 어길수록 독성이 높을 것
검증	두 조건의 위반 개수(0~2)별 독성 비율
결과·효과	채택. 0개 43.3%(5,656개) → 1개 47.6%(1,916개) → 2개 57.5%(777개)
그림 점검	logP 조건에 가설 1 효과가 섞여 있다. 분자량만의 효과는 clogp 구간을 고정하고 봐야 한다

함께 점검한 것: 이상치와 다중공선성

점검	무엇인가	결과	결정
이상치 (IQR)	가운데 50%가 퍼진 폭의 1.5배 밖 값	분자량 이상치 130개의 독성 22% (전체 46%), sa_score 158개는 31%	지우지 않음. 이상치가 신호다
다중공선성 (VIF)	한 변수를 나머지로 설명할 수 있는 정도, 10 넘으면 겹침	최대 2.85(MolWt). MolWt-qed 상관 −0.75	4개 모두 유지

주의: VIF를 상수항 없이 계산하면 MolWt 34.4, sa_score 27.4로 부풀어 지우지 않아도 될 변수를 지우게 된다.

가설 4 · 독성 정보는 물성보다 구조에 있다

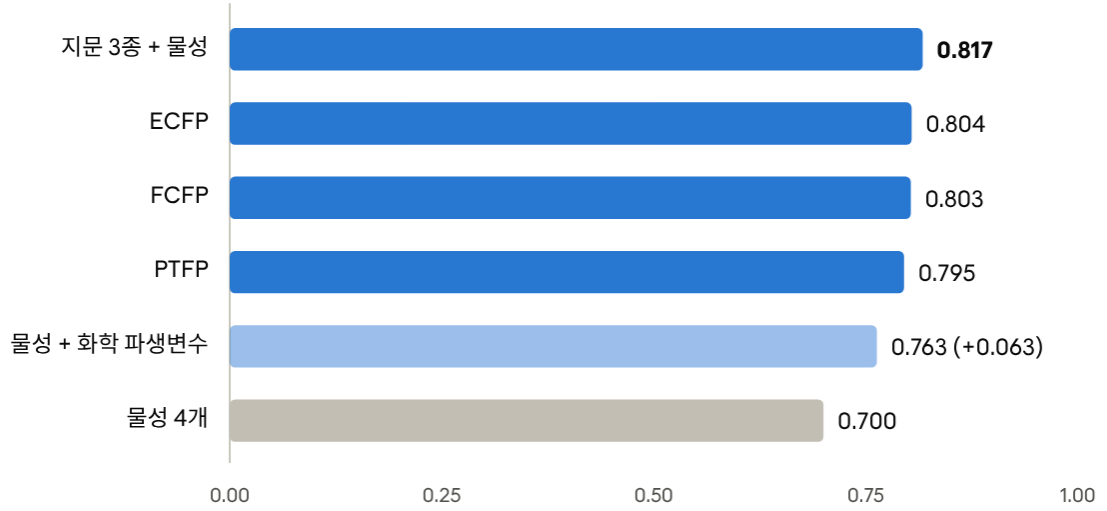
한 줄 결론: 물성만 쓰면 F1 0.70, 구조 지문을 쓰면 0.82(+0.12).

단계	내용
관찰	가장 강한 물성 clogp도 AUC 0.66이 한계. PCA 2차원에서도 두 라벨이 섞여 있고 두 축이 정보의 5%만 설명
가설	독성을 가르는 정보는 구조(지문)에 더 많다

단계	내용
검증	같은 RandomForest에 피처 묶음만 바꿔 넣고 F1 비교
결과·효과	채택. 물성 0.70 → 지문 하나 0.80 → 지문 3종 + 물성 0.82. 독성 재현율 0.63 → 0.76
그림 점검	지문 3종 사이 차이(0.795~0.804)는 fold 편차(±0.01) 수준이라 순위는 결론으로 쓰지 않는다

구조 지문을 쓰면 F1이 0.70에서 0.82로 오른다

같은 RandomForest에 피처 묶음만 바꿔 넣은 F1, 섞은 5-fold 평균



연한 파랑 = 가설 8의 화학 파생변수를 물성에 더한 모델, 회색 = 물성만

train.csv 8,349건 · RandomForest 150그루, StratifiedKFold(5, shuffle=True, random_state=42)

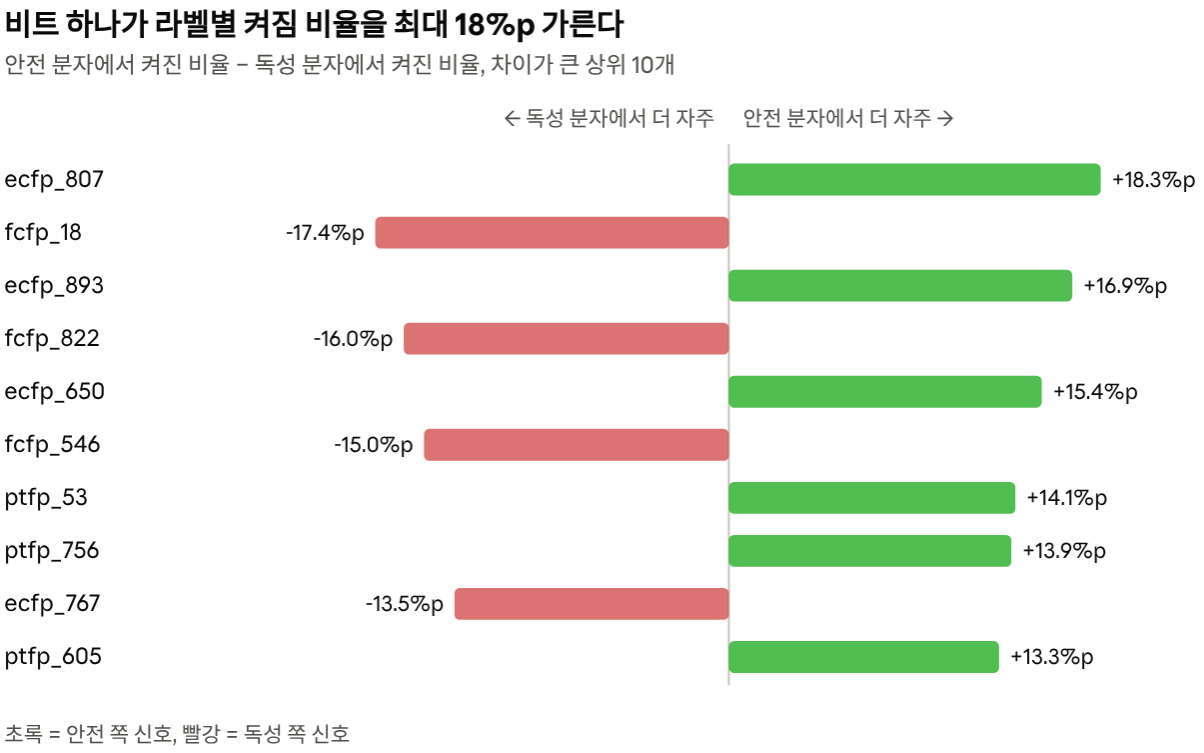
용어 · **지문(fingerprint)** 분자에 특정 부분구조가 있으면 1, 없으면 0인 1,024칸 체크리스트. ECFP는 원자 연결, FCFP는 원자 역할, PTFP는 대표 부분구조 기준 · ECFP·FCFP는 1인 칸이 5%로 희소하고 PTFP는 42%로 빽빽해 성격이 다르다

가설 5 · 특정 부분구조가 독성을 가른다

한 줄 결론: 독성 쪽 대표 비트 fcfp_18은 염기성 질소(3차 아민)로 보이고, 지용성까지 높으면 독성 72%다.

단계	내용
관찰	지문이 강하다면(가설 4) 3,072칸 중 일부가 일을 할 것이다
가설	특정 비트는 독성/안전 분자에서 켜지는 비율이 크게 다를 것

단계	내용
검증	비트마다 (안전에서 켜진 비율 − 독성에서 켜진 비율), 상위 비트는 RDKit으로 분자 그림 확인
결과·효과	채택. 비트 하나가 최대 18%p를 가른다. fcfp_18이 켜지면 독성 54.5%(4,041개), 꺼지면 37.2%
시행착오	"독성 분자에 자주 나오는 비트 수"는 AUC 0.50. 흔한 비트는 양쪽에 다 많아서 **빈도가 아니라 차이**로 골라야 했다



train.csv 8,349건 · 지문 3,072비트 중 차이 상위 10개

fcfp_18은 무슨 구조인가

이 비트가 켜진 분자 6개를 그려 보면(발표 자료 11쪽) 모두 고리나 사슬 끝에 **3차 아민 질소**(N-메틸 등)를 갖는다. 몸속에서 양이온이 되는 염기성 질소다. 지용성과 함께 보면 효과가 커진다.

clogp 구간	fcfp_18 켜짐	fcfp_18 꺼짐
3 미만	29.6%	22.6%
3~4.5	57.2%	40.5%
4.5 이상	**71.6%**	47.9%

기름에 잘 녹으면서 양이온이 되는 분자는 세포막에 쌓이기 쉬운 것으로 알려져 있어 가설 1과 이어진다. 단, 비트 하나에 여러 구조가 겹칠 수 있어 "로 보인다" 수준의 해석이다.

가설 6·7 · QSAR: 닮은 분자는 독성도 닮는다

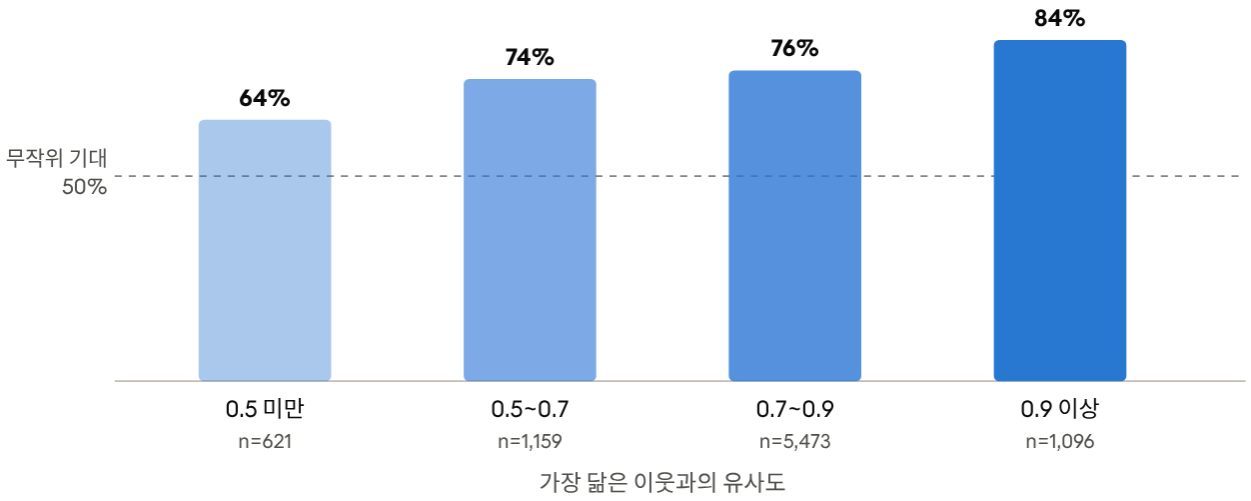
한 줄 결론: 가장 닮은 분자와 라벨 일치 76%(무작위 50%). 단, 이웃 라벨을 변수로 넣는 건 효과 없음.

QSAR이란? "구조가 비슷한 물질은 성질도 비슷하다"는 가정으로 구조에서 독성을 예측하는 방법. 닮은 정도는 두 분자 지문이 겹치는 비율(Tanimoto 유사도, 0~1)로 잔다.

단계	가설 6	가설 7
관찰	분자의 79%가 유사도 0.7 이상인 이웃을 가진다	가설 6이 성립했다
가설	구조가 닮으면 독성도 닮는다	이웃 라벨 평균을 변수로 넣으면 모델이 좋아진다
검증	가장 닮은 분자와 라벨 일치율, kNN	fold 안에서만 계산해 RF에 추가
결과·효과	**채택.** 일치 76%, 0.9 이상은 84%. kNN(k=3) F1 0.78	**기각.** F1 0.817 → 0.818, 독성 재현율 0.759 → 0.766
주의	유사도 0.8 이상 5,756쌍 중 20%는 라벨 반대 (activity cliff)	그 정보는 이미 지문에 있다

더 닮은 분자일수록 라벨이 같을 확률이 64%에서 84%로 오른다

가장 닮은 이웃과 라벨이 같은 비율 (전체 76%), 유사도 = ECFP Tanimoto



train.csv 8,349건 · 분자마다 가장 닮은 1개(자기 자신 제외), ECFP Tanimoto

용어 · **activity cliff** 거의 같은 구조인데 작은 부분 하나 때문에 성질이 크게 달라지는 현상 · **kNN** 가장 닮은 k개의 다수결로 예측

가설 8 · 산성기·산소는 안전, 방향족·니트로는 독성

한 줄 결론: 화학 지식으로 만든 파생변수가 물성 모델을 F1 0.70 → 0.76(+0.06) 올렸다.

단계	내용
관찰	물성에서는 지용성이 가장 강했고(가설 1), 지문 비트는 무슨 구조인지 설명이 어렵다
가설	같은 현상을 화학자가 아는 구조로도 볼 수 있을 것
검증	SMILES에서 정규식으로 파생변수 13개를 만들어 카이제곱 검정·단일 AUC, 그리고 모델에 더해 F1 비교
결과·효과	채택. 물성 모델 F1 0.700 → 0.763, 독성 재현율 0.627 → 0.696. 지문 모델엔 효과 없음(0.817 → 0.816)

구조	쉽게 말하면	결과 (전체 독성 45.6%)	판정
카복실산기	몸에서 이온이 돼 세포막을 잘 못 지나감	독성 29.0% (806개, p<0.001)	채택
산소 원자 수	물과 친한(극성) 성질 → 지용성을 낮춤	많을수록 안전 (AUC 0.63)	채택
방향족 원자 비율	평평한 고리, DNA·단백질 틈에 끼어듦	많을수록 독성 (AUC 0.44)	채택
니트로기	대표적인 독성 경고 구조	독성 71.4% (35개, p=0.004)	채택, 표본 적음
염소(Cl)	할로겐 원소	독성 49.9% (1,871개, p<0.001)	채택
브롬(Br)	할로겐 원소	독성 52.1% (169개, p=0.10)	보류
전하를 띤 분자	이온 상태	독성 56.3% (151개, p=0.01)	약하게 채택
마이켈 받개	반응성 구조라 독성 예상	독성 27.5% (51개)	반대 결과, 확인 필요
clogp ÷ 분자량	작은데 기름진 분자	AUC 0.34 (clogp와 같음)	기각

그림 점검 · 단일 변수 검정이라 다른 변수 효과가 섞여 있다. 카복실산이 안전한 게 "산성기" 때문인지 "낮은 지용성" 때문인지는 clogp 구간을 고정해 봐야 한다. 정규식은 RDKit보다 엉성하다.

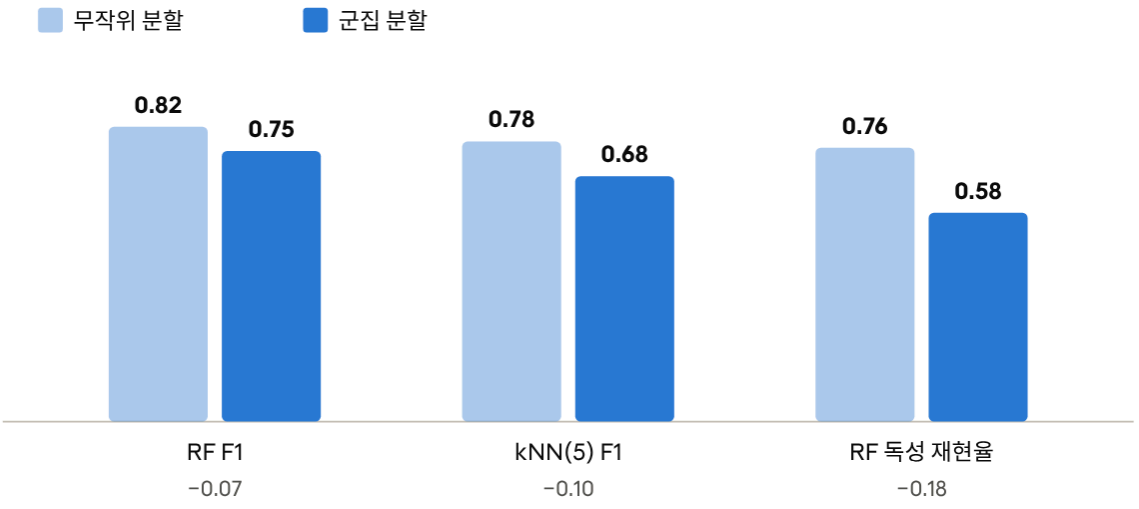
가설 9·10 · 점수는 검증 방식이 정한다

한 줄 결론: 처음 보는 계열의 분자에서는 독성 물질의 42%를 놓친다.

단계	가설 9 · 행 순서	가설 10 · 닮은 분자 암기
관찰	첫 행 94Da, 마지막 행 1,242Da. 팀 노트북은 섞지 않고 5-fold를 했다	분자 79%가 아주 닮은 이웃을 가진다(가설 6)
가설	섞지 않으면 가벼운 분자로 배워 무거운 분자를 맞히는 시험이 돼 점수가 낮다	무작위로 나누면 시험에 거의 같은 분자가 나와 점수가 부푼다
검증	섞기 전후 F1 비교	유사도 0.6 이상끼리 군집(2,237개)으로 묶어 군집 단위로 나눔(GroupKFold)
결과·효과	**채택.** F1 0.72 → 0.82	**채택.** RF F1 0.82 → 0.75, 독성 재현율 0.76 → 0.58, kNN 0.78 → 0.68

닮은 분자를 시험에서 빼면 독성 재현율이 0.76에서 0.58로 떨어진다

5-fold 평균. 군집 분할 = 유사도 0.6 이상인 분자끼리 같은 fold에 묶음



train.csv 8,349건 · RandomForest 150그루, kNN = ECFP Tanimoto 상위 5개 다수결 · 군집 2,237개

비유로 보면 · **무작위 분할**은 연습문제와 거의 같은 문제가 시험에 나오는 상황이고, **군집 분할**은 처음 보는 유형으로 치는 시험이다. kNN이 더 많이 떨어진 건 암기에 더 기대는 방식이기 때문이다. 학습 데이터와의 유사도별 정확도는 0.5 미만 75%, 0.9 이상 85%다.

결론과 Day 2로 넘길 것

구조가 주연, 지용성이 조연이고, 모델보다 평가 설계가 먼저다. 오늘 결론은 "무엇이 독성과 함께 움직이나"이지 "무엇이 독성을 일으키나"가 아니고, 모든 숫자는 train 안에서만 확인했다.

- [ ] 모든 비교는 같은 분할로, 섞은 5-fold와 군집 분할 점수를 함께 보고

- [ ] RF·XGBoost·LightGBM과 Tanimoto kNN(k=3) 비교
- [ ] F1과 함께 독성 재현율 보고, 임계값 조정으로 독성 재현율 올리기
- [ ] 거의 상수인 컬럼(ECFP 99, FCFP 424, PTFP 200개) 제거 전후 비교
- [ ] predict_input 927건의 train 유사도 분포 확인, 유사도로 예측 신뢰도 표시
- [ ] 가설 3·8을 clogp 구간을 고정한 채로 다시 확인
- [ ] 화학 파생변수를 RDKit으로 정확하게 다시 만들기

파일과 재현 방법

모든 파일은 train.csv와 같은 폴더에 두고 실행한다. 환경은 `uv add pandas numpy matplotlib seaborn scipy scikit-learn jupyter ipykernel`로 만든다.

파일	내용	관련 가설
EDA_따라하기_독성예측.ipynb	데이터 이해, 물성 분포, 지문, 핵심 비트, PCA	데이터 이해, 1, 2, 5
EDA_추가분석_가설검증.ipynb	clogp 구간, Lipinski, QSAR 유사도, 원소 검정	1, 3, 6, 8
심화분석_재현.py	VIF·이상치, 빈도 기반 비트 수, 화학 파생변수, kNN, QSAR 변수, 군집 분할	3, 5, 6, 7, 8, 10
효과측정_재현.py	피처 묶음별 F1·독성 재현율 (섞은 5-fold)	4, 8, 9
발표용_그래프.zip	발표 자료에 들어간 그래프 원본	전체

주의: 팀 노트북 Step 15의 F1은 섞지 않은 5-fold라 낮게 나온다(가설 9). 다시 돌릴 때는 `cv=StratifiedKFold(5, shuffle=True, random_state=42)`를 넣는다.